

# 基于深度学习算法的带钢表面缺陷识别

王立中, 管声启

(西安工程大学 机电工程学院, 陕西 西安 710048)

**摘要:**为了解决带钢表面缺陷识别过程中的特征不能自动准确提取的问题,给出了基于深度学习算法的带钢表面缺陷识别的新方法.本文在分析深度学习基本理论的基础上,建立了带钢表面识别的基础模型;然后,通过训练样本图像获取基础模型参数.该模型通过多隐层逐层抽取图像特征,从而自动获取目标的本质特征,进而进行识别分类;最后,通过实验验证本文算法的有效性.实验结果表明,本文带钢表面缺陷识别的准确率能达到 98% 以上,满足了带钢识别的要求.

**关键词:**带钢表面;深度学习;分类准确性;缺陷识别

**中图分类号:**TH 83

**文献标识码:**A

## Strip steel surface defect recognition based on deep learning

WANG Lizhong, GUAN Shengqi

(School of Mechanical and Electrical Engineering, Xi'an Polytechnic University, Xi'an 710048, China)

**Abstract:** In order to solve the problem that the features in the process of strip surface defect identification can not be automatically and accurately extracted. In this paper, a new approach to strip surface defect recognition based on deep learning is proposed. This paper first analyzes the basic theory of deep learning, on the basis of this, the basic model of strip surface recognition is established. Then the basic model parameters are trained by the prepared training images. The model extracts image features layer by layer through hidden layers, thus automatically acquire the essential characteristics of the target. Identification and classification are performed. Finally, the validity of the model is verified by testing image. The experimental results show that the accuracy of strip surface defect identification can reach more than 98%, it meets the requirements of strip steel identification.

**收稿日期:**2017-07-10

**基金项目:**西安市科技计划项目(2017074CG/RC037(XAGC006))

**通讯作者:**管声启(1971—),男,安徽省庆安市人,西安工程大学副教授,博士,研究方向为图像处理、机器人视觉等.

E-mail: sinal1300841@163.com

**引文格式:**王立中,管声启.基于深度学习算法的带钢表面缺陷识别[J].西安工程大学学报,2017,31(5):669-674.

WANG Lizhong, GUAN Shengqi. Strip steel surface defect recognition based on deep learning[J]. Journal of Xi'an Polytechnic University, 2017, 31(5): 669-674.

**Key words:** strip steel surface; deep learning; classification accuracy; defect recognition

## 0 引言

带钢外观质量检测是带钢质量控制重要环节之一<sup>[1]</sup>,其外观质量直接影响着产品质量等级评价,进而影响产品竞争力.传统的带钢缺陷检测方法一直采用人工开卷抽检或频闪光检测方法进行表面质量检测<sup>[2-3]</sup>,经过概率计算并参考检测人员的经验数据形成带卷的综合质量评定.然而传统方法存在诸多弊端:(1)缺乏检测的一致性、科学性,主要依赖检测人员的主观判断,由于不同质检人员经验水平不同,对同一缺陷会得出不同的判断,导致缺陷种类、级别不准,从而降低了检测的可信度;(2)检测环境恶劣枯燥,对人的身心危害很大,检测人员的劳动强度大,极易疲乏,容易造成误判和漏检.

随着计算机技术、图像处理技术的发展,基于图像处理的带钢表面质量自动检测与识别将成为可能<sup>[4-5]</sup>.文献[6]在缺陷图片特征向量选取的基础上,分别采用BP神经网络和支持向量机2种模式识别进行判定,但是此方法在提取特征向量的方式不够鲁棒,识别准确率不高;文献[7]通过在AdaBoost算法的每个循环中通过Relief算法进行特征的筛选与降维,通过筛选后的特征利用样本的类内类间差去除噪声样本,然后根据AdaBoost的动态权值更新样本库,再利用每个循环优化选择得到的最优特征与弱分类器级联成最终的AdaBoost强分类器来进行带钢表面缺陷识别,此方法在准确率上有所提升但是在图像抗噪性上不强.

从上述文献可以看出目前基于图像处理的带钢表面质量检测主要是由人工确定带钢表面缺陷的图像特征,然后使用分类器进行识别.而传统的模式识别方法需要依靠经验确定识别的特征,很难满足不同条件下采集到的特征各异的带钢表面缺陷图像的识别需要.

为了解决带钢缺陷特征提取问题,提高带钢缺陷识别准确率,本文给出了基于深度学习的方法来识别带钢表面缺陷.通过深度学习,逐层自动提取带钢表面的本质特征,避免因采集的图像质量不高影响缺陷识别准确率,从而提高识别效果.

## 1 深度学习理论分析

深度学习模型属于神经网络<sup>[8]</sup>,而神经网络通过模拟大脑认知机理,解决各种机器学习问题;由于神经网络有大量的参数,经常发生过拟合问题,虽然其识别结果在训练集上准确率很高,但在测试集上效果却很差.因此更多学者采用诸如支持向量机等分类器,这些分类器可以具有一个或两个隐含层的神经网络模拟,因而被称为浅机器学习模型,不再模拟大脑的认知机理,在这种模型中,往往是针对不同的任务设计不同的系统,并采用不同的手工设计的特征.2006年,Geoffrey Hinton提出深度学习,之后深度学习在诸多领域取得了巨大成功,受到广泛关注.

深度学习与传统模式识别方法的最大不同在于它所采用的特征是从大数据中自动学习得到,深度学习可以针对图像的分层特征表达进行:最底层从原始像素开始学习滤波器,刻画局部的边缘和纹理特征;中层滤波器通过将各种边缘滤波器进行组合,描述不同类型的目标特征;最高层描述的是整个目标的全局特征.并且在深度学习神经网络的框架下,特征表示和分类器是联合优化的,可以最大程度的发挥二者联合协作的性能<sup>[9]</sup>.

正是因为深度学习能够自动刻画样本特征,从而避免人工提取特征的缺陷,所以本文利用深度学习<sup>[10]</sup>建立带钢表面缺陷检测的网络模型,通过卷积神经网络进行深度学习,实现精确刻画带钢缺陷特征,从而提高了带钢缺陷识别的准确性.

## 2 带钢表面缺陷识别网络模型

深度学习包括循环神经网络(RNN, recurrent neural networks)和卷积神经网络(CNN, convolutional neural network)等几个大类.其中RNN层与层之间是全连接的,且不同于其他神经网络,其隐藏层之间的节点是有连接的,并且隐藏层的输入不仅包括输入层的输出还包括上一时刻隐藏层的输出,而自然语言中句子里前后单词也不是独立的而是相互联系的,所以RNN多用于处理语音、文本等.而CNN的输入可以是图像(多维数组),本质是利用庞大的数据通过滤波器对图像进行多次滤波和下采样不断降维,再加上

激活函数的非线性拟合不断获取更加抽象且更深层次的目标本质特征,从而实现对目标的识别,以解决以往需要人工设计特征的重要难题.所以基于CNN的深度学习模型适合于处理图像等相关机器学习问题.

因此,本文的带钢表面缺陷识别中采用CNN模型,CNN基本隐层包括卷积(convolution)层,激活函数(relu)层,下采样(pool)层,和全连接(fc)层,如图1所示.

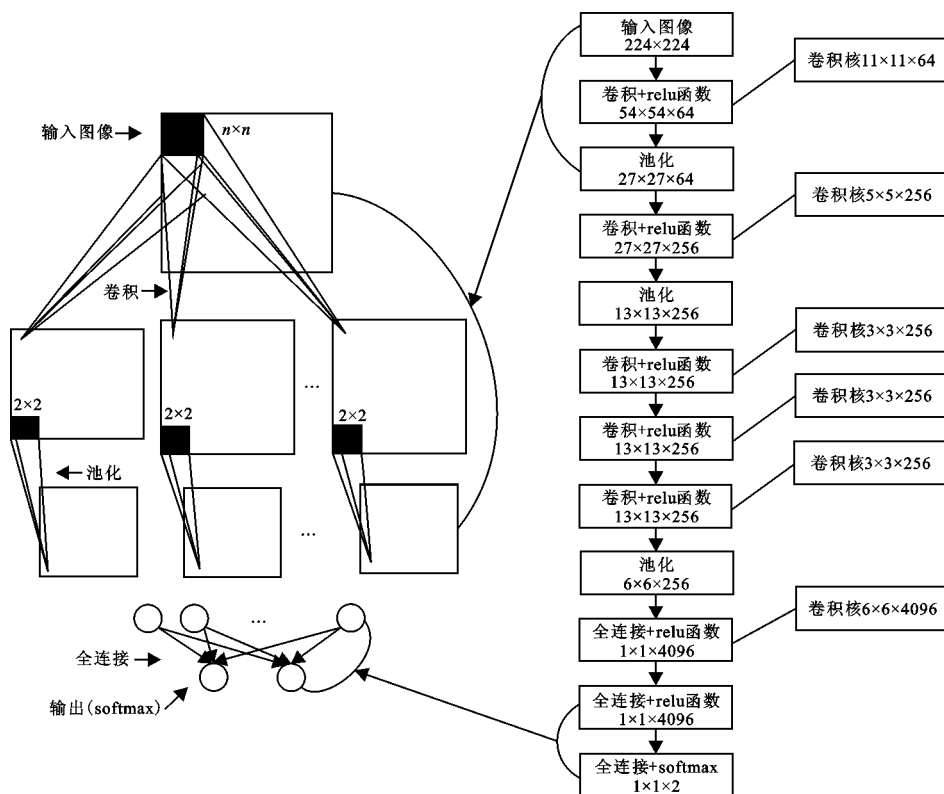


图1 带钢表面缺陷识别网络模型

Fig. 1 Strip surface defect recognition network model

网络的输入图像首先经过卷积层,具体操作为:设置一个 $n \times n$ 的卷积核,在图像上每滑动一定的步长与对应的像素相乘后累加,用式(1)表示为

$$y = \sum_{i=1}^n \sum_{j=1}^n \omega_{ij} x_{ij} + b. \quad (1)$$

其中: $\omega$ 为卷积核上的参数有 $n \times n$ (远小于图像分辨率)个,不同的卷积核有不同的参数,有多少个卷积核,就输出多少个特征图像. $x$ 为卷积核对应位置上图像的像素值, $b$ 为修正参数, $y$ 为输出值输入relu函数,用式(2)表示为

$$f(x) = \begin{cases} 0 & (x < 0) \\ x & (x \geq 0) \end{cases}. \quad (2)$$

输出值 $f(x)$ 作为这一层特征图像(feature map)所对应的一个像素点的值.接下来为池化层,在上一层输出的特征图像上一般选取 $2 \times 2$ 的滑窗,选取滑窗中最大的像素值作为这一层特征图像所对应的一个像素值.全连接层的输入与输出,用式(3)表示为

$$y = \sum_{i=1}^n \omega_i x_i + b. \quad (3)$$

其中: $n$ 为这一层全连接层向量的维度大小, $\omega, x, b$ 意义与式(1)一样.最后一个全连接层的输出值经过softmax函数,用式(4)表示为

$$y_i = \frac{\exp(z_i)}{\sum_{j=1}^k \exp(z_j)}. \quad (4)$$

其中: $z$ 为输出向量的其中一个元素的值, $k$ 为输出向量的维度大小,对元素值取指数后进行计算,就将输

出值都映射到 $(0,1)$ 之间,且映射后的所有数值相加后为 1,所以每一维的输出值也就相当于这一维所对应分类类别的概率.当某一维的值最大时则认为输入的样本是这一维所对应的类别.

在训练网络时当样本进入网络正向传播后得到的输出值会与事先标定的图像标签进行比对,计算损失值(loss),用式(5)表示为

$$L_i = -\ln \left[ \frac{\exp(z_i)}{\sum_j \exp(z_j)} \right]. \quad (5)$$

其中: $i$ 为真实标签对应输出某一维的位置,也就是对这一维 softmax 输出值取负对数,这样真实标签对应位置的输出值越小则 loss 值越大.

然后进入反向传播阶段,采用 sgd 算法<sup>[11]</sup>更新优化模型参数.建立带钢表面缺陷识别模型,如图 1 所示.此网络由 5 个卷积层(convolution),3 个下采样(pool)层和 3 个全连接(fc)层构成,由于本次实验数据集分为有缺陷和无缺陷 2 种类别,所以把最后一个全连接层的输出维度由默认值 1 000 改为 2.

### 3 实验

#### 3.1 实验数据集

本次实验总共有 1 200 幅带钢表面图像,包含有缺陷图像 514 幅和无缺陷图像 686 幅,选取其中 1 000 幅图像(有缺陷图像 450 幅,无缺陷图像 550 幅)作为训练样本,剩余 200 幅图像(有缺陷图像 64 幅,无缺陷图像 136 幅)作为测试样本,带钢图像如图 2 所示.




图 2 带钢图像示例

Fig. 2 Strip image

由于深度学习需要大量的样本进行学习,如果样本数量不大,容易造成过拟合<sup>[12]</sup>的现象,而本次实验数据集集中的 1 200 幅样本远远不够.所以本文采用增广数据集和加入 Dropout<sup>[13]</sup>的方法来减小过拟合现象.

这里采用水平翻转和亮度变换的方法来增广数据集,如图 3 所示.使用 Matlab 对每一幅样本做如图 3(a)的水平翻转和的图 3(c)的亮度变换,这样数据集可以产生新的可学习的样本以减小过拟合现象,然后对每一副图像打上标签 1 或 0,1 对应无缺陷的带钢图像,0 对应有缺陷的带钢图像.




图 3 图片变换结果

Fig. 3 Picture conversion results

3.2 带钢缺陷识别模型训练

因为训练带钢缺陷识别模型时初始训练参数对最后的训练结果影响较大,所以本次实验采用 fine-tuning<sup>[14]</sup>的方法,选用在 imagenet 数据集上训练好的模型参数作为初始参数.这样避免了因数据集不充足而造成训练效果不理想的情况.本次实验训练框架采用 Matlab 的深度学习工具箱 matconvnet<sup>[15]</sup>.设置总迭代轮数为 30 轮,调整 SGD 算法反向传播的学习率和 batchsize(每一批送入模型训练的图片数目)等参数后得到最优结果,如表 1 所示.

由表 1 可知,batchsize 取 8 且学习率取 0.000 1 时训

练模型的测试集损失值最小,所以此时模型效果最好.损失值变化过程如图 4 所示.纵坐标表示损失值大小,横坐标表示训练的轮数.每一个节点表示每一轮训练完后产生的损失值,两条曲线分别代表训练集的损失值变化和测试集的损失值变化.由图 4 可知,当经过 10 轮的迭代后,损失值基本收敛,最终训练集损失值降为 0.002,同时测试集损失值降为 0.302.

3.3 带钢缺陷识别模型效果分析

将测试集的 200 张图片输入 3.2 节训练好的网络模型,定量测试带钢表面缺陷识别模型的准确率.有 197 幅输出的最大概率与标签一致,测试准确率为 98.5%.为了测试模型对图像噪声的抗干扰能力,将测试图像分别加入高斯噪声和椒盐噪声,如图 5 所示.将加入两种噪声后的图像分别输入上述训练好的模型,测试结果表明含高斯噪声和椒盐噪声带钢缺陷识别率均为 97.5%,表明基于 CNN 的带钢表面缺陷识别模型具有很强的抗噪性.

4 结束语

为提高带钢缺陷在线识别准确率,本文将深度学习算法引入到带钢缺陷识别,通过研究深度学习的基本理论,建立带钢表面缺陷检测的网络模型并进行相应参数优化,然后利用训练后的网络用于带钢缺陷识别.实验表明本文所采用的识别方法具有较高的准确率和抗干扰性,因而能够较好满足工业产品表面质量检测的要求.




图 5 加入噪声后的图像

Fig. 5 The picture adding noise

参考文献(References):

[1] 刘坤,陈宁纪,张晓峰,等.基于机器视觉的带钢表面缺陷检测系统设计[J].制造业自动化,2015,34(12):134-137.  
LIU K,CHEN N J,ZANG X Y,et al. Defect detection system design for steel surface based on machine vision[J]. Manufacturing Automation,2015,34(12):134-137.  
[2] 董志洪,李立复.板带生产工艺现状及其发展趋势[J].钢铁,1999,34(11):68-71.

表 1 各参数对模型准确率影响结果

Table 1 Effect of parameters on model accuracy

batchsize	参数	学习率	测试集损失值
4		0.000 1	0.352
8		0.000 1	0.302
16		0.000 1	0.381
8		0.001	0.381
8		0.000 01	0.345




图 4 训练过程中损失值变化过程

Fig. 4 Change process of lost value during training

- DONG Z H, LI L F. Present situation and improvement tendency of hot rolling strip production technique[J]. Steel, 1999, 34(11): 68-71.
- [3] 高雪梅. 基于机器视觉的带钢表面缺陷检测系统研究[D]. 保定: 河北大学, 2011: 1-3.
- GAO X M. Research on strip surface defect detection system based on machine vision[D]. Baoding: Master Thesis of Hebei University, 2011: 1-3.
- [4] JAYASHREE V, SUBBARAMAN S. Identification of plain grey fabric defects using DC suppressed Fourier power spectrum sum features[J]. Meliand China, 2012, 82(14): 1485-1497.
- [5] 赵霆, 管声启, 王鹏. 基于目标面积特征分析的带钢缺陷图像分割方法[J]. 西安工程大学学报, 2015, 29(4): 477-481.
- ZHAO T, GUAN S Q, WANG P. A steel defect image segmentation method based on target's area characteristic analysis[J]. Journal of Xi'an Polytechnic University, 2015, 29(4): 477-481.
- [6] 王森, 朱凯. 基于模式识别的带钢表面缺陷等级判定的研究[J]. 现代制造工程, 2016(11): 119-123.
- WANG S, ZHU K. The research of predicating the defect class of strip steel surface based on pattern recognition[J]. Modern Manufacturing Engineering, 2016(11): 119-123.
- [7] 刘坤, 赵帅帅, 屈尔庆, 等. R-AdaBoost 带钢表面缺陷特征选择算法[J]. 电子测量与仪器学报, 2017, 31(1): 9-14.
- LIU K, ZHAO S S, QU E Q, et al. R-AdaBoost strip surface defect feature selection algorithm[J]. Journal of Electronic Measurement and Instrument, 2017, 31(1): 9-14.
- [8] KOPRINKOVA-HRISTOVA P, MLADENOV V, KASABOV N K. Artificial neural networks[J]. European Urology, 2015, 40(1): 245.
- [9] 孙志军, 薛磊, 许阳明, 等. 深度学习研究综述[J]. 计算机应用研究, 2012, 29(8): 2806-2810.
- SUN Z J, XUE L, XU Y M, et al. Overview of deep learning[J]. Application Research of Computers, 2012, 29(8): 2806-2810.
- [10] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [11] LECUN Y, BOSER B, DENKER J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.
- [12] HAWKINS D M. The problem of overfitting[J]. Cheminform, 2004, 35(19): 1.
- [13] BALDI P, SADOWSKI P. The dropout learning algorithm[J]. Artificial Intelligence, 2014(210): 78-122.
- [14] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313: 504-507.
- [15] VEDALDI A, LENC K. Matconvnet: Convolutional neural networks for Matlab[C]//Proceedings of the 23rd ACM International Conference on Multimedia, ACM: Brishane, 2015: 689-692.

责任编辑: 孟 超